

Billboard x Spotify: Rendimiento en streaming vs éxito en las listas

Partes Interesadas: Equipos de Marketing, A&R (Artist and Repertoire), Analistas de Datos en la Industria Musical

Tema:

En este caso de estudio se explorará la relación entre el rendimiento de las canciones dentro de las listas de Billboard y su éxito en las mismas.

Problema:

La industria musical depende en gran medida de la predicción de qué canción se convertirá en un éxito. Sin embargo, no siempre es tan claro decir que el rendimiento en plataformas de streaming y las características de la canción son indicadores confiables dentro del éxito de las listas.

Este análisis apunta a determinar qué factores son más asociados en una canción para convertirse en un hit.

Pregunta de negocio:

Identificar si las métricas y características de las canciones en plataformas de streaming pueden explicar o predecir el éxito de la misma dentro de las lista de Billboard

Métricas:

Las siguientes métricas se utilizarán para evaluar el éxito:

- Puntaje de popularidad de Spotify
- Posición en la lista de Billboard
- Presencia en la lista de Billboard (hit vs no hit)
- Características de la canción

Audiencia:

Profesionales en la industria musical que estén involucrados en la toma de decisiones relacionadas a la promoción de artistas o estrategias de lanzamiento.

Hallazgos:

Los hallazgos de este análisis que podrán ayudar a las partes interesadas:

- Identificar las características de canciones exitosas
 - Mejorar estrategias de marketing y promoción
 - Mejor asignación de recursos de canciones a potenciales éxitos
-

Preparacion

Fuentes de Datos

Los datos utilizados en este análisis provienen de dos bases de datos disponibles públicamente en Kaggle:

- **Spotify Songs Analytics Dataset:** Contiene información sobre las canciones disponibles en Spotify, incluyendo sus características y otros atributos necesarios para el análisis.
- **Billboard Historical Charts Dataset:** Incluye el ranking semanal, canciones, nombres de los artistas, fechas en las que aparece en las listas, distribuidas en diferentes archivos CSV.

Organización y ubicación de los datos

Las dos bases de datos fueron descargadas desde Kaggle y guardadas localmente. Se crearon copias de cada archivo que se utilizará para asegurarse que los datos originales se mantengan dentro del proceso de limpieza y análisis

Credibilidad de los Datos (ROCCC)

- **Confiables:** Los conjuntos de datos se utilizan habitualmente con fines educativos y analíticos, aunque no son exportaciones oficiales de API.
- **Originales:** Los datos se recopilan de Spotify y Billboard y se comparten a través de Kaggle.
- **Completo:** Ambos conjuntos de datos incluyen un gran número de registros y variables relevantes para el análisis.
- **Actualizados:** Es posible que el conjunto de datos de Spotify no esté completamente actualizado, lo que podría limitar la obtención de información en tiempo real. El conjunto de datos de Billboard se actualiza periódicamente; sin embargo, este análisis utiliza una versión estática disponible al momento de la preparación del proyecto.

- **Citas:** Si bien los conjuntos de datos son de acceso público, los métodos originales de recopilación de datos de Spotify no están completamente documentados. Se asume que los datos de Billboard se recopilaban de sus listas de éxitos publicadas oficialmente.

Verificación de la integridad de los datos

Para garantizar la calidad de los datos, se realizarán los siguientes pasos:

- Verificación de valores faltantes o nulos
- Identificación y eliminación de registros duplicados
- Estandarización de campos de texto como títulos de canciones y nombres de artistas
- Revisión de formatos de datos (p. ej., fechas y valores numéricos) para verificar su coherencia

Relevancia de los Datos

Los conjuntos de datos están directamente alineados con la tarea empresarial:

- El conjunto de datos de Spotify proporciona métricas relacionadas con la reproducción en streaming y características de audio.
- El conjunto de datos de Billboard proporciona datos oficiales sobre el rendimiento en las listas de éxitos.

En conjunto, permiten analizar la relación entre el rendimiento en streaming y el éxito en las listas.

Limitaciones y posibles problemas de los datos

- Los datos podrían no estar completamente actualizados.
- Inconsistencias en los campos de texto (p. ej., títulos de canciones, nombres de artistas).
- Diferencias de formato (p. ej., estructura de fechas).
- Posible sesgo hacia la música popular o de amplia difusión.

Accesibilidad de datos, privacidad y licencias

- El conjunto de datos de Spotify tiene licencia CC0 (Dominio Público) y es de uso gratuito.

- El conjunto de datos de Billboard tiene licencia CC BY-NC-SA 4.0 y se utiliza con fines educativos y no comerciales, con la debida atribución.
 - Ambos conjuntos de datos están disponibles públicamente en Kaggle.
 - No se incluye información personal ni datos confidenciales de los usuarios.
 - Los datos se utilizan de conformidad con los términos de uso de Kaggle.
-

Proceso

Para el conjunto de datos de Spotify, se utilizaron Google Sheets y BigQuery para la limpieza y el preprocesamiento de datos.

Para el conjunto de datos de Billboard, se utilizó exclusivamente BigQuery debido a su mayor tamaño y complejidad. Se excluyeron los archivos CSV de Billboard Radio, canciones en streaming y canciones digitales, ya que este análisis se centra específicamente en las listas de éxitos.

El conjunto de datos de Spotify contenía inicialmente 955 filas y 24 columnas, incluyendo variables como el nombre de la canción, el artista, el número de artistas colaboradores, los componentes de la fecha de lanzamiento (año, mes, día), la presencia en listas de reproducción de Spotify, Apple Music y Deezer, las clasificaciones en múltiples plataformas (Spotify, Apple Music, Deezer, Shazam), el total de reproducciones, BPM, tonalidad, modo musical y varias características de audio (danzabilidad, valencia, energía, acústica, instrumentalidad, inmediatez y presencia de voz).

Durante el proceso de limpieza de datos:

- Se identificaron y eliminaron los espacios en blanco en las celdas B214 y B274.
- No se encontraron registros duplicados.
- No se detectaron valores nulos.
- La fila 576 se eliminó debido a inconsistencias en los datos que no pudieron corregirse de forma fiable.
- La fila 376 se eliminó porque no contenía un nombre de pista válido, solo símbolos ilegibles.
- Se creó una nueva columna, «fecha_de_lanzamiento», combinando el día, el mes y el año de lanzamiento para estandarizar el formato de fecha en todos los conjuntos de datos. Posteriormente, se eliminaron las tres columnas originales para mayor claridad.

- Las columnas de características de audio (danzabilidad, valencia, energía, acústica, instrumentalidad, vivacidad y habla) se convirtieron a formato porcentual para mayor coherencia.
- Los valores faltantes en la columna «Gráficos de Shazam» se reemplazaron por 0.
- Los valores faltantes en la columna «clave» se reemplazaron por «desconocido».

Tras estos pasos, se utilizó SQL en BigQuery para finalizar el proceso de limpieza. Se creó una nueva columna, “clean_track_name”, para estandarizar los nombres de las pistas eliminando información innecesaria como los artistas invitados:

```
CREATE OR REPLACE TABLE
capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_final AS

SELECT

*,

  TRIM(REGEXP_REPLACE(track_name, r'\(\\s*(?i:feat|ft|with|featuring)\\b[^)]*\\)',
  '')) AS clean_track_name

FROM capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned
```

El conjunto de datos de Billboard comprende varios archivos CSV, cada uno de los cuales representa una categoría de lista diferente (para este análisis, utilizaremos únicamente Billboard Hot 100). El conjunto de datos incluye:

- Billboard Hot 100 (350.79K filas)

Todos los conjuntos de datos comparten la misma estructura, con columnas idénticas: fecha de la lista, título de la canción, artista, posición en el ranking, posición de la semana anterior, posición máxima, semanas en la lista y URL de la imagen.

Como parte de la fase de preprocesamiento, la columna originalmente llamada "fecha" se estandarizó a "chart_date" en todas las tablas para evitar conflictos con las palabras clave reservadas de SQL y mejorar la claridad.

Se aplicó un proceso de limpieza de datos consistente a cada conjunto de datos individualmente debido a su estructura idéntica. Este proceso incluyó:

- Detección de duplicados
- Validación de valores nulos

- Comprobación de espacios en blanco
- Validación de tipo y formato de datos
- Validación de fechas
- Detección de caracteres inusuales o inconsistentes en campos de texto

Tras realizar estas comprobaciones, no se encontraron valores nulos en el conjunto de datos.

Se verificó que todos los registros fueran consistentes con sus formatos esperados, incluyendo fechas y campos numéricos. No se identificaron entradas duplicadas ni se detectaron problemas de formato o espacios en blanco no deseados.

En general, se determinó que los conjuntos de datos de Billboard eran limpios, consistentes y adecuados para análisis posteriores.

Analisis

Construccion de la puntuacion de popularidad de spotify

Para cuantificar la popularidad de las canciones dentro del conjunto de datos de Spotify, se creó una puntuación compuesta utilizando tres métricas clave:

- Reproducciones totales
- Presencia en listas de reproducción en todas las plataformas
- Presencia en listas de éxitos en todas las plataformas

Las reproducciones en streaming recibieron una ponderación mayor (0,6) ya que representan directamente la interacción de los oyentes, mientras que la presencia en listas de reproducción y listas de éxitos (0,2 cada una) se consideraron indicadores complementarios de exposición.

Para calcular la puntuación se utilizó la siguiente consulta:

```
CREATE OR REPLACE TABLE
capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_analisis_v1 AS
WITH base AS (
  SELECT
    track_name,
    artist_s__name,
    streams,
    release_date,
```

```

    (in_spotify_playlists + in_apple_playlists + in_deezer_playlists) AS
Total_playlist,
    (in_spotify_charts + in_apple_charts + in_deezer_charts + in_shazam_charts) AS
Total_charts,
    (
        LOG(streams + 1) * 0.6 +
        LOG(in_spotify_playlists + in_apple_playlists + in_deezer_playlists + 1) * 0.2
    +
        LOG(in_spotify_charts + in_apple_charts + in_deezer_charts + in_shazam_charts
+ 1) * 0.2
    ) AS raw_score
FROM capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned
)
SELECT
    *,
    100 * (
        (raw_score - MIN(raw_score) OVER()) /
        (MAX(raw_score) OVER() - MIN(raw_score) OVER())
    ) AS score_100
FROM base;

```

La métrica score_100 reescala la puntuación bruta a un rango de 0 a 100, lo que mejora su interpretabilidad.

Un análisis inicial sugirió que un alto número de reproducciones no se corresponde necesariamente con una mayor presencia en las listas de éxitos o de reproducción, lo que indica que la popularidad no depende de un único factor.

Métricas de rendimiento de Billboard

Para analizar el rendimiento en las listas, se establecieron dos definiciones de éxito:

- Rendimiento máximo → puesto más alto alcanzado (min_rank)
- Longevidad → número total de semanas en la lista (max_weeks_in_charts)

El análisis se limitó al período 2020-2023 para que coincidiera con el conjunto de datos de Spotify.

```

CREATE OR REPLACE TABLE
`capstone-spotify-x-billboard.Billboard_Dataset.Bilboard_hot_100_analysis`
AS
SELECT
  Song,
  Artist,
  MIN(chart_date) AS first_chart_date,
  MAX(chart_date) AS last_chart_date,
  MIN(Rank) AS min_rank,
  MAX(SAFE_CAST(`Weeks in Charts` AS INT64)) AS max_weeks_in_charts
FROM `capstone-spotify-x-billboard.Billboard_Dataset.Bilboard_hot_100`
WHERE chart_date BETWEEN '2020-01-01' AND '2023-12-31'
GROUP BY 1, 2;

```

Normalizacion de Datos

Para garantizar uniones precisas, se estandarizaron los nombres de las canciones y de los artistas:

```

CREATE OR REPLACE TABLE
`capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_analisis_v2` AS
SELECT
  *,
  INITCAP(TRIM(LOWER(REGEXP_REPLACE(track_name, r'\(.*?\)', '')))) AS Song,
  INITCAP(TRIM(LOWER(REGEXP_REPLACE(artist_s__name, r'\(.*?\)', '')))) AS Artist
FROM capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_analisis_v1;

```

Spotify vs Rendimiento en listas

La combinación de ambos conjuntos de datos permitió una comparación directa entre la puntuación de Spotify y las semanas en las listas, y otra comparación entre la puntuación de Spotify y el ranking.

```

SELECT
  b.Artist,
  b.Song,
  b.min_rank,
  b.max_weeks_in_charts,
  b.first_chart_date,
  b.last_chart_date,
  s.score_100 AS spotify_score
FROM `capstone-spotify-x-billboard.Billboard_Dataset.Bilboard_hot_100_analysis` AS b
INNER JOIN
`capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_analisis_v2` AS s
ON b.Song = s.Song

```





```
AND b.Artist = s.Artist
ORDER BY b.min_rank ASC;
```

Para cuantificar las relaciones:

Fila	corr_rank_vs_spotify	corr_weeks_vs_spotify
1	-0.34319281808116953	0.65739502258225357

```
SELECT
CORR(s.score_100, b.min_rank) AS corr_rank_vs_spotify,
CORR(s.score_100, b.max_weeks_in_charts) AS corr_weeks_vs_spotify
FROM `capstone-spotify-x-billboard.Billboard_Dataset.Bilboard_hot_100_analysis` b
INNER JOIN
`capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_analysis_v2` s
ON b.Song = s.Song
AND b.Artist = s.Artist;
```



Principales hallazgos

- Correlación negativa débil entre el puesto en la lista y la puntuación de Spotify
- Correlación positiva moderada entre las semanas en la lista y la puntuación de Spotify

Esto sugiere que la permanencia es un mejor indicador de la popularidad real que la posición máxima alcanzada.

Clasificación de Hit

Las canciones se clasificaron según su rendimiento para definir qué tipo de éxito representan en el conjunto de datos de Billboard:

- **Éxito instantáneo** → pico alto, corta duración
- **Éxito duradero** → permanencia prolongada en las listas
- **Otros**

```
SELECT
CASE
  WHEN b.min_rank <= 10 AND b.max_weeks_in_charts <= 20 THEN 'Instant Hit'
  WHEN b.max_weeks_in_charts > 20 THEN 'Durable Hit'
  ELSE 'Other'
END AS hit_category,
AVG(s.score_100) AS avg_spotify_score,
COUNT(*) AS total_songs
FROM capstone-spotify-x-billboard.Billboard_Dataset.Bilboard_hot_100_analysis b
JOIN capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned_analisis_v2 s
ON b.Song = s.Song
AND b.Artist = s.Artist
GROUP BY hit_category;
```

Fila	hit_category ▾	avg_spotify_score ▾	total_songs ▾
1	Other	69.74120170865...	117
2	Instant Hit	74.49130128734...	24
3	Durable Hit	83.68776777633...	75

Hallazgo

Los éxitos duraderos muestran sistemáticamente puntuaciones más altas en Spotify, lo que refuerza la idea de que una presencia constante en las listas de éxitos se corresponde con el comportamiento de los oyentes.

Analisis de Caracteristicas de las canciones

Para comprender cómo suenan las canciones exitosas, se incorporaron características de audio a una nueva tabla para un análisis mejor y más detallado:

```
CREATE OR REPLACE TABLE
`capstone-spotify-x-billboard.Billboard_Dataset.Characteristics_hits`
AS
SELECT
  b.Song,
  b.Artist,
  MIN(b.min_rank) AS min_rank,
  MAX(b.max_weeks_in_charts) AS max_weeks_in_charts,
  AVG(s.`danceability_%`) AS danceability,
  AVG(s.`energy_%`) AS energy,
  AVG(s.`valence_%`) AS valence,
  AVG(s.`acousticness_%`) AS acousticness,
  AVG(s.`instrumentalness_%`) AS instrumentalness,
  AVG(s.`liveness_%`) AS liveness,
  AVG(s.`speechiness_%`) AS speechiness
FROM `capstone-spotify-x-billboard.Billboard_Dataset.Bilboard_hot_100_analysis` b
JOIN `capstone-spotify-x-billboard.Billboard_Dataset.Spotify_cleaned` s
ON b.Song = s.track_name
AND b.Artist = s.artist_s__name
GROUP BY b.Song, b.Artist;
```

Comparacion por categoria:

```
SELECT
  CASE
    WHEN max_weeks_in_charts > 20 THEN 'Durable Hit'
    ELSE 'Other'
```


```

END AS category,
AVG(danceability) AS Danceability,
AVG(energy) AS Energy,
AVG(valence) AS Valence,
AVG(acousticness) AS Acousticness,
AVG(instrumentalness) AS Instrumentalness,
AVG(liveness) AS Liveness,
AVG(speechiness) AS Speechiness
FROM capstone-spotify-x-billboard.Billboard_Dataset.Characteristics_hits
GROUP BY category;

```

Fila	category	Danceability	Energy	Valence
1	Other	0.642699999999...	0.584366666666...	0.464800000000...
2	Durable Hit	0.656268656716...	0.627014925373...	0.542537313432...

Acousticness	Instrumentalness	Liveness	Speechiness
0.303699999999...	0.019000000000...	0.180566666666...	0.097033333333...
0.303134328358...	0.002985074626...	0.175820895522...	0.068656716417...



Hallazgo final

Los éxitos perdurables suelen ser:

- Más bailables

- Más enérgicos
- Con un tono más positivo
- Menos acústicos y menos instrumentales

Sin embargo, estas diferencias son moderadas, lo que significa que las características de audio contribuyen al éxito, pero no lo determinan por completo.

Conclusión

Este análisis demuestra que:

- La posición más alta en las listas no refleja con precisión la popularidad general.
- La longevidad es un indicador más fiable del compromiso sostenido de los oyentes.
- Las características de audio influyen, pero no son decisivas por sí solas.

En resumen podemos decir que el éxito en la música no se define por una sola métrica, sino por una combinación de rendimiento, constancia y comportamiento del oyente.